

Clasificación de Sentimientos en Reseñas de E-Commerce

Comparación del Desempeño entre Regresión Logística (TF-IDF) y Redes Neuronales Profundas (Keras) en Reseñas de Amazon.

Estudiante: Guillermo Nieto Soriano

Curso / Fecha: Módulos y paquetes para Machine Learning | 12/09/2026




⚠ Planteamiento del Problema

🖥 El Desafío en el Comercio Electrónico

- ❖ **Volumen Masivo de Datos:** Las tiendas de e-commerce reciben miles de opiniones diarias, imposibles de analizar manualmente.
- 🎧 **Atención al Cliente Prioritaria:** Identificar opiniones negativas en tiempo real permite responder inmediatamente a clientes insatisfechos.
- 🕒 **Detección de Defectos:** Permite aislar rápidamente lotes o productos defectuosos antes de que afecten la reputación de la marca.

Pregunta de Investigación: ¿Puede un modelo de Deep Learning superar en precisión y F1-Score a un modelo lineal tradicional TF-IDF al clasificar opiniones automáticas?

```
sns.countplot(  
    x="sentimiento",  
    data=df  
)  
  
plt.title("Distribución de sentimientos")  
plt.show()
```



🎯 Objetivos del Proyecto

🚩 Objetivo General

Desarrollar y comparar un pipeline completo de Procesamiento de Lenguaje Natural (NLP) aplicando Regresión Logística y Redes Neuronales en TensorFlow/Keras para predecir automáticamente el sentimiento en reseñas de productos de e-commerce.

🔧 Objetivos Específicos

🔹 **Ingesta y Limpieza:** Concatenar título y cuerpo de reseña, eliminando ruido, puntuación y URLs.

📊 **Análisis EDA:** Explorar la distribución de calificaciones y diagnosticar el desbalance de clases.

🧠 **Modelo Deep Learning & Comparación:** Diseñar una Red Neuronal secuencial con capas de Embedding y evaluar ambos modelos mediante F1-Score Macro.

⚙️ **Preprocesamiento NLP:** Tokenizar, remover stopwords en inglés y aplicar lematización con NLTK.

🔗 **Modelo TF-IDF:** Entrenar un baseline de Regresión Logística con ponderación balanceada de clases.

Estructura del Dataset

Información del Dataset

Archivo: comercio-opiniones.csv (Reseñas de Amazon).

Idioma original: Inglés.

Campos clave: reviews.text, reviews.title, reviews.rating, reviews.doRecommend.

Archivo: comercio-opiniones.csv (Reseñas de Amazon).

Idioma original: Inglés.

Campos clave: reviews.text, reviews.title, reviews.rating, reviews.doRecommend.

Definición de Variable Objetivo

Se creó la variable binaria **sentimiento**:

- **1 (Positivo)**: Si `reviews.rating` ≥ 4 estrellas.
- **0 (Negativo)**: Si `reviews.rating` < 4 estrellas.

Se creó la variable binaria **sentimiento**:

- **1 (Positivo):** Si `reviews.rating` ≥ 4 estrellas.
- **0 (Negativo):** Si `reviews.rating` < 4 estrellas.

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 34660 entries, 0 to 34659
Data columns (total 21 columns):
#   Column                                Non-Null Count  Dtype
--  --
0   id                                     34660 non-null  object
1   name                                  27900 non-null  object
2   asins                                 34658 non-null  object
3   brand                                34660 non-null  object
4   categories                           34660 non-null  object
5   keys                                  34660 non-null  object
6   manufacturer                         34660 non-null  object
7   reviews.date                         34621 non-null  object
8   reviews.dateAdded                   24039 non-null  object
9   reviews.dateSeen                   34660 non-null  object
10  reviews.didPurchase                 1 non-null      object
```

```
df.describe()
```


	reviews.id	reviews.numHelpful	reviews.rating	reviews.userCity	reviews.userProvince
count	1.0	34131.000000	34627.000000	0.0	0.0
mean	111372787.0	0.630248	4.584573	NaN	NaN
std	NaN	13.215775	0.735653	NaN	NaN
min	111372787.0	0.000000	1.000000	NaN	NaN
25%	111372787.0	0.000000	4.000000	NaN	NaN
50%	111372787.0	0.000000	5.000000	NaN	NaN
75%	111372787.0	0.000000	5.000000	NaN	NaN
max	111372787.0	814.000000	5.000000	NaN	NaN

📊 Análisis Exploratorio de Datos (EDA)

🔍 Hallazgos Principales

- ★ **Predominio de Calificaciones Altas:** La mayoría de reseñas se concentran en 4 y 5 estrellas, reflejando clientes mayoritariamente satisfechos.
- ⚖️ **Desbalance Mercado de Clases:** Las opiniones positivas (1) superan ampliamente a las negativas (0), generando un desbalance crítico.
- 🛡️ **Estrategia de Mitigación:** Se requiere aplicar `class_weight="balanced"` en ambos modelos para evitar sesgos hacia la clase dominante.

```
plt.figure(figsize=(6,4))  
  
sns.countplot(x="reviews.rating", data=df)  
  
plt.title("Distribución de puntuaciones")  
  
plt.xlabel("Estrellas")  
  
plt.show()
```



A Análisis de Texto y N-Gramas

Patrones Léxicos Identificados

Reseñas Positivas: Abundancia de términos como *"great"*, *"love"*, *"good"*, *"easy"* y *"product"*.


Reseñas Negativas: Presencia clave de términos de frustración como *"not"*, *"disappointed"*, *"broke"*, *"bad"* y *"return"*.

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

sns.barplot(x=[c for _, c in top_pos], y=[p for p, _ in top_pos], ax=axes[0], color="seagreen")
axes[0].set_title("Palabras más frecuentes - Reseñas positivas")

sns.barplot(x=[c for _, c in top_neg], y=[p for p, _ in top_neg], ax=axes[1], color="indianred")
axes[1].set_title("Palabras más frecuentes - Reseñas negativas")

plt.tight_layout()
plt.show()
```



NATURAL LANGUAGE PROCESSING

7 KEY TECHNIQUES



Pipeline Metodológico de NLP



Modelo 1: Regresión Logística + TF-IDF

Configuración del Modelo

Vectorizador: TfidfVectorizer (max_features=5000, n-gramas 1-2).

Parámetros: class_weight="balanced", max_iter=1000.

Ventajas: Rápido entrenamiento, interpretable y alta eficiencia conceptual.

Resultados Obtenidos

Accuracy

[ACCURACY_RL]


F1-Score (Macro)

[F1_MACRO_RL]

```
cm_dl = confusion_matrix(y_test, y_pred_dl)

plt.figure(figsize=(5, 4))
sns.heatmap(cm_dl, annot=True, fmt="d", cmap="Purples",
            xticklabels=["Negativa", "Positiva"], yticklabels=["Negativa", "Positiva"])
plt.title("Matriz de confusión - Red Neuronal (Deep Learning)")
plt.xlabel("Predicción")
plt.ylabel("Real")
plt.show()
```

Matriz de confusión - Red Neuronal (Deep Learning)



Modelo 2: Red Neuronal en TensorFlow/Keras

Arquitectura de la Red

Embedding(10000, 32) → GlobalAveragePooling1D → Dense(16, relu) → Dropout(0.3) → Dense(1, sigmoid)

Tokenización: VOCAB_SIZE=10000, MAX_LEN=100, 10 épocas, batch_size=64, class_weight calculado mediante compute_class_weight.

Resultados Obtenidos

Accuracy

[ACCURACY_RN]

F1-Score (Macro)


[F1_MACRO_RN]

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

axes[0].plot(historia.history["accuracy"], label="Train")
axes[0].plot(historia.history["val_accuracy"], label="Validación")
axes[0].set_title("Accuracy por época")
axes[0].set_xlabel("Época")
axes[0].legend()

axes[1].plot(historia.history["loss"], label="Train")
axes[1].plot(historia.history["val_loss"], label="Validación")
axes[1].set_title("Loss por época")
axes[1].set_xlabel("Época")
axes[1].legend()

plt.tight_layout()
plt.show()
```



⚖️ Comparación de Desempeño


Tabla Comparativa

Modelo	Accuracy	F1-Score (Macro)
Regresión Logística (TF-IDF)	[A [ACC_RL]	[F [F1_RL]
Red Neuronal (Keras Embedding)	[A [ACC_RN]	[F [F1_RN]

💡 **Interpretación:** Ambos modelos demuestran un rendimiento sólido; el ajuste por peso de clases permite capturar eficazmente la clase minoritaria (negativa) manteniendo un balance óptimo en el F1-Score macro.

```
comparacion_melt = comparacion.melt(id_vars="Modelo", var_name="Métrica", value_name="Valor")

plt.figure(figsize=(8, 5))
sns.barplot(data=comparacion_melt, x="Métrica", y="Valor", hue="Modelo")
plt.title("Comparación de desempeño entre modelos")
plt.ylim(0, 1)
plt.legend(loc="lower right")
plt.show()
```



🚩 Conclusiones y Limitaciones

✅ Conclusiones Clave

La concatenación de título y texto mejoró sensiblemente el contexto lingüístico de las reseñas.

La lematización y el filtrado de stopwords en NLTK redujeron efectivamente la dimensionalidad del vocabulario.

El ajuste de pesos de clase (`class_weight`) fue crucial para prevenir sesgos en la clase negativa.

TF-IDF + Regresión Logística demostró ser un baseline excepcionalmente competitivo, rápido y liviano.

⚠️ Limitaciones Identificadas

Idioma exclusivo: El pipeline NLTK actual está diseñado solo para inglés.

Extensión a Español: Requiere adaptar el preprocesamiento usando librerías como `spaCy` con el modelo `es_core_news_sm` y stopwords en español.

Truncamiento: `MAX_LEN=100` puede omitir contexto en reseñas extremadamente largas.

🔮 Trabajo Futuro

Implementar embeddings preentrenados (GloVe/FastText) o arquitecturas basadas en Transformers (BERT/RoBERTa), aumentar las épocas de entrenamiento y realizar un fine-tuning más extenso de hiperparámetros.