



Carrera: Ingeniería de Software con IA

FUNDAMENTOS Y ALGORITMIA

PARA INTELIGENCIA ARTIFICIAL



RESULTADO DE APRENDIZAJE:

Al finalizar la sesión, el estudiante interpreta los datos como representaciones matemáticas y aplica medidas de distancia para comprender el funcionamiento del algoritmo KNN, identificando la influencia del valor de K, el escalamiento y las principales limitaciones del algoritmo.

CONTENIDO:

- Representación matemática de los datos
- Datos como puntos en el espacio
- Geometría aplicada al Machine Learning
- Medidas de distancia
- Fundamentos de KNN
- KNN para clasificación
- Escalamiento de variables
- Limitaciones de KNN
- Overfitting y underfitting

Recordando...

- **Registro / Instancia:** Fila completa (cliente, paciente, imagen).
- **Característica / Feature:** Columna o atributo medible (edad, ingresos).
- **Variable Independiente:** Atributo predictivo de entrada.
- **Variable Objetivo / Target:** Lo que queremos predecir (etiqueta).

El Vector de **Características**

La máquina no entiende conceptos abstractos, opera con vectores numéricos ordenados.

$$X = (35, 3500, 1200)$$

Representa un cliente con 35 años, 3500 de ingresos y 1200 de deuda.

Cada variable es una coordenada en el espacio.

¿Qué es KNN?

Algoritmo de Machine Learning supervisado

Clasificación y regresión

KNN (K-Nearest Neighbors) o **K vecinos más cercanos** es un algoritmo de **Machine Learning supervisado** que se utiliza principalmente para **clasificación** y también para **regresión**.

Clasifica un nuevo dato según sus vecinos más cercanos.

Geometría aplicada al aprendizaje automático



1 Dimensión (1D)

Una sola variable (ejemplo: Edad). Las observaciones son puntos ordenados sobre una recta numérica.



2 Dimensiones (2D)

Dos variables (ejemplo: Edad e Ingresos). Las observaciones se ubican en un plano cartesiano (Pitágoras).




N Dimensiones (ND)

Espacios multidimensionales. Las distancias se calculan matemáticamente aunque superen nuestra intuición visual.


Geometría aplicada al aprendizaje automático

1D — Recta



Edad: cada persona es un punto en una línea.

2D — Plano



(Edad, Ingresos): cada persona es un punto en el plano.

3D — Espacio



(35, 3500, 1200): un punto flotando en el espacio.

ND — Multidim.

- Edad
- Ingresos
- Deuda
- Puntuación
- Antigüedad
- ...

No se puede visualizar, pero sí calcular: KNN funciona igual en N dimensiones.

Descripción del lenguaje geométrico de KNN

Punto

Una observación: el vector de características.

Coordenadas

Cada variable es una coordenada del punto.

Distancia

Qué tan separados están dos puntos la base de KNN.

Cercanía

Dos puntos son cercanos si su distancia es pequeña.

Similitud

A menor distancia, mayor similitud entre observaciones.

Dirección

En KNN clásico importa poco; sí en otros algoritmos.

Distribución de puntos

Zonas densas, vacías o mezcladas: KNN aprovecha la distribución local.

KNN transforma la clasificación en un problema geométrico: para predecir, mira qué puntos están cerca en el espacio de características.

Distancia euclidiana (L2)

Es la medida geométrica en línea recta entre dos puntos en un espacio n-dimensional. Constituye la generalización directa del **Teorema de Pitágoras**.

$$d(x,y) = \sqrt{\sum (x_i - y_i)^2}$$

Uso típico: Datos continuos con escalas normalizadas y dimensiones bajas o moderadas.

Distancia euclidiana (L2)

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

EJEMPLO 2D

$$A = (2, 3) \quad B = (5, 7)$$

$$d = \sqrt{(2-5)^2 + (3-7)^2}$$

$$d = \sqrt{(-3)^2 + (-4)^2}$$

$$d = \sqrt{9 + 16} = \sqrt{25}$$

$$d = 5$$

Distancia en línea recta entre dos puntos. Generaliza el teorema de Pitágoras a cualquier número de dimensiones.

Ejercicios:

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

1. Dados los puntos: $A=(6,10)$ $B=(23,3)$
Calcular: la distancia euclidiana entre A y B.

Ejemplo:

Tenemos: $P=(4,4)$

Calcular:

- $d(P,A)$
- $d(P,B)$
- $d(P,C)$

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Punto	X	Y
A	2	3
B	8	7
C	5	5

¿Cuál de los tres puntos es el **vecino más cercano** de P?

Ejemplo:

Tenemos: $P=(4,4)$

Punto	X	Y
A	2	3
B	8	7
C	5	5

Recordar:

- $P=(x_1,y_1)$
- $Q=(x_2,y_2)$

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Calculamos distancias:

$P=(4,4)$ $A=(2,3)$

Aplicamos formula:

$$d(P,A)=\sqrt{(2-4)^2+(3-4)^2}$$

$$d(P,A)=\sqrt{5}$$

$$d(P,A)\approx 2.24$$

$P=(4,4)$ $B=(8,7)$

Aplicamos formula:

$$d(P,B)=\sqrt{(8-4)^2+(7-4)^2}$$

$$d(P,B)=\sqrt{25}$$

$$d(P,B)= 5$$

$P=(4,4)$ $C=(5,5)$

Aplicamos formula:

$$d(P,C)=\sqrt{(5-4)^2+(5-4)^2}$$

$$d(P,C)=\sqrt{2}$$

$$d(P,C)\approx 1.41$$

$$1.41 < 2.24 < 5$$

C es el vecino más cercano a P

K = 1

Ejercicio:

Tenemos: $P=(6,4)$

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Punto	X	Y
A	3	2
B	7	5
C	9	3
D	5	6

Calcula:

- $d(P,A)=?$
- $d(P,B)=?$
- $d(P,C)=?$
- $d(P,D)=?$

- ¿Cuál es el punto más cercano a P?
- ¿Cuál es el punto más lejano?

Otras métricas: Manhattan y Minkowski

Distancia Manhattan (L1)

Suma de diferencias absolutas. Simula desplazamientos en cuadrícula urbana.

$$d = \sum |x_i - y_i|$$

Ventaja: Mayor robustez frente a valores atípicos (outliers) extremos.


Distancia Minkowski

Generalización parametrizada que unifica métricas mediante el exponente p .

$$d = (\sum |x_i - y_i|^p)^{1/p}$$

Si $p=1$ es Manhattan, si $p=2$ es Euclidiana.

Otras métricas: Manhattan



También llamada distancia de taxista o L1. Solo se avanza por los ejes, como en una cuadrícula de calles.

$$d = \sum |x_i - y_i|$$

EJEMPLO 2D

$$A = (2, 3) \quad B = (5, 7)$$

$$d = |2-5| + |3-7| = 3 + 4$$

$$d = 7$$

vs. Euclidiana (5): la Manhattan es mayor.
Ventaja: más robusta a outliers.

Desventaja: menos intuitiva en espacios continuos.

Otras métricas: Minkowski

$$d = (\sum |x_i - y_i|^p)^{1/p}$$

$$p = 1$$

Distancia Manhattan

Suma de diferencias absolutas por eje.

$$p = 2$$

Distancia Euclidiana

La clásica línea recta entre dos puntos.

$$p \rightarrow \infty$$

Distancia Chebyshev

El máximo de las diferencias absolutas.


Permite ajustar la sensibilidad a diferencias grandes o pequeñas: en KNN se puede elegir p según el problema.

Otras métricas: Minkowski

Distancia	Idea	Uso típico
Euclidiana	Distancia directa, línea recta	Datos continuos, baja dimensión
Manhattan	Distancia por ejes, como una ciudad	Datos con outliers, alta dimensión
Minkowski	Generalización de ambas	Ajuste flexible según el problema

¿Qué distancia usarías si tus variables son coordenadas GPS? ¿Y si son conteos de palabras en un texto?

Flujo completo de KNN



En regresión, en lugar de votar, se promedian los valores de los K vecinos.

KNN en Scikit-Learn

```
from sklearn.neighbors import KNeighborsClassifier  
knn = KNeighborsClassifier(n_neighbors=5)  
knn.fit(X_train_scaled, y_train)  
y_pred = knn.predict(X_test_scaled)
```

K: el número de vecinos que decide

K = 1 (Alta Varianza / Overfitting): Solo consulta al vecino más cercano. Muy susceptible al ruido y errores de etiquetado local.

K Intermedio (K = 3, 5): Suaviza la frontera de decisión y mitiga el impacto de puntos atípicos individuales.

! **K Grande (Alto Sesgo / Underfitting):** Genera un modelo excesivamente generalizado que incluye vecinos lejanos no representativos.

☑ Emplear valores impares en clasificación binaria para evitar empates sistemáticos.

K: el número de vecinos que decide

K = 1

*Alta varianza · bajo
sesgo · overfitting*

K = 3

Punto intermedio

K = 5

*Puede ignorar patrones
locales finos*

K grande

*Alto sesgo · baja
varianza · underfitting*

K: el número de vecinos que decide

Ejemplo:

$K=1 \rightarrow 0.82$; $K=3 \rightarrow 0.87$; $K=5 \rightarrow 0.89$.

No existe un K universalmente correcto.

KNN Ponderado por distancia

En el KNN estándar, todos los vecinos seleccionados poseen idéntica influencia en la votación final. El KNN ponderado asigna mayor peso a los puntos más cercanos geométricamente.

$$w_i = 1 / (d_i + \epsilon)$$

Donde ***di*** es la distancia al vecino y ϵ evita la división por cero.

Ventajas Operativas

Reduce drásticamente la distorsión provocada por vecinos periféricos dentro del radio de K.

Resuelve de forma elegante los empates en votaciones complejas.

Incrementa la precisión general en distribuciones de datos densas y solapadas.

Determinar qué clase domina entre los vecinos

K = 3

Vecinos más cercanos:



Votos: A = 2 · B = 1

Predicción: Clase A

K = 5

Vecinos más cercanos:



Votos: A = 2 · B = 3

Predicción: Clase B

El mismo vecindario, distinto K, distinta predicción: el valor de K puede cambiar el resultado.

¿Qué ocurre si hay empate?

Con $K = 4$: 2 vecinos de clase A y 2 vecinos de clase B → empate.

1

Usar K impar

Evita empates directamente en clasificación binaria.

2

KNN ponderado

El vecino más cercano pesa más y puede desempatar.

3

Regla de desempate

Clase mayoritaria global, o alfabética (poco recomendable).

4

Suma de distancias

Se elige la clase cuyos vecinos tengan menor suma de distancias.

Recomendación: diseñar el experimento para minimizar empates. En problemas multiclase, evitar K múltiplo del número de clases.

No todos los vecinos pesan igual

En KNN estándar todos los vecinos votan igual. Pero los más cercanos deberían influir más.

$$w_i = 1 / (d_i + \varepsilon)$$

w_i: peso del vecino i · d_i: su distancia · ε evita dividir por cero

Vecino	Clase	Distancia	Peso
1	A	1	1.00
2	B	2	0.50
3	A	3	0.33

Suma A = 1.00 + 0.33 = 1.33 Suma B = 0.50

Predicción: Clase A

Ventajas: reduce el impacto de vecinos lejanos y ayuda con empates. **Desventajas:** más costoso computacionalmente y requiere elegir la función de peso.

Normalización vs. Estandarización

Normalización Min-Max

Reescala el rango de las variables estrictamente entre $[0, 1]$.

$$x_{\text{norm}} = (x - \min) / (\max - \min)$$

Sensible a outliers: Un valor extremo comprime el rango del resto de observaciones.

Estandarización Z-score

Centra las variables con media $\mu = 0$ y desviación estándar $\sigma = 1$.

$$z = (x - \mu) / \sigma$$

Robusta: Maneja de manera mucho más eficiente la presencia de valores atípicos.

Normalización vs. Estandarización

NORMALIZACIÓN

$$x_{norm} = (x - min) / (max - min)$$

Rango objetivo: [0, 1]

Edad 18–70: 44 → $(44 - 18) / (70 - 18) = 0.5$

Ingresos 1000–20000: 10500 → $9500 / 19000 = 0.5$

Ventaja: fácil de interpretar.

Desventaja: sensible a outliers.

Ambas variables ahora contribuyen equitativamente.

ESTANDARIZACIÓN

$$z = (x - \mu) / \sigma$$

μ : media σ : desviación estándar

Edad ($\mu=40$, $\sigma=10$): 70 → $(70 - 40) / 10 = 3.0$

Ingresos ($\mu=8000$, $\sigma=4000$): 20000 → 3.0

Ventaja: menos sensible a outliers.

Desventaja: no acota el rango; asume normalidad.

Centra los datos en 0 con desviación estándar 1.

KNN: desafíos en producción y escala



Algoritmo “Lazy”

No genera un modelo paramétrico en entrenamiento. Su costo computacional:

$$O(N \times D)$$

recae totalmente en la fase de inferencia.



Sensibilidad al ruido

Vulnerable a datos mal etiquetados o valores atípicos aislados que corrompen la vecindad inmediata.



Clases desbalanceadas

Tiende a favorecer la clase mayoritaria en votaciones locales si la densidad de puntos es asimétrica.

KNN: desafíos en producción y escala

1

Costo computacional

KNN es “lazy”: predecir cuesta $O(N \times D)$. Con millones de datos, es lento.

KD-Trees / Ball Trees ayudan, pero sufren en alta dimensión.

2

Datos ruidosos

Un punto mal etiquetado o un outlier afecta la predicción, sobre todo con K pequeño.

Mitigación: K más grande, KNN ponderado, limpiar datos.

3

Variables irrelevantes

Distorsionan la distancia: vecinos no similares pueden parecer cercanos.

Mitigación: selección de características, PCA, conocimiento del dominio.

4

Clases desbalanceadas

Si una clase es más frecuente, KNN tiende a predecirla.

Mitigación: KNN ponderado, oversampling/undersampling, métricas como F1 o AUC.

5

Elección de K

K pequeño → overfitting.
K grande → underfitting.

La validación cruzada es el método confiable para elegirlo.

KNN: desafíos en producción y escala


K MUY PEQUEÑO

Overfitting: el modelo memoriza el ruido. Buen rendimiento en entrenamiento, malo en prueba.

K MUY GRANDE

Underfitting: el modelo es demasiado simple. Mal rendimiento en entrenamiento y en prueba.

Error según el valor de K



$K = \sqrt{N}$ es una heurística de partida. La **validación cruzada** es el método confiable para encontrar el mínimo de validación.

**“La cercanía también
es información”**